GPT from Scratch
Arabic Kids Stories

By Khulud Alsultan

12/03/2026

Introduction

- This project is developed to build and train GPT from scratch to write Arabic kids stories
- The raw dataset consists of 5 text files (4 of them collected manually)
- Data Summary:
- Number of lines: 425615
- File size: 20.87 MB

Hyperparameters

- vocab_size = 8000
- layers = 4
- heads = 4
- epochs = 2
- lr = 3e-4
- d_model = 256
- dropout = 0.1

Pre-trained Model Demo

Step 4: Pretraining

```python
import torch

print("CUDA available:", torch.cuda.is_available())
print("GPU:", torch.cuda.get_device_name(0))
```

```
CUDA available: True
GPU: NVIDIA RTX PRO 6000 Blackwell Server Edition
```

```
!python /content/drive/MyDrive/gpt-from-scratch/src/training/pretrain.py
```

```
Streaming output truncated to the last 5000 lines.
epoch 0 | step 107400 | loss 1.3469
```

[46]
44m

```
!python /content/drive/MyDrive/gpt-from-scratch/src/training/pretrain.py
```

```
Streaming output truncated to the last 5000 lines.
epoch 0 | step 107400 | loss 1.3469
epoch 0 | step 107500 | loss 1.6044
epoch 0 | step 107600 | loss 1.5738
epoch 0 | step 107700 | loss 1.3861
epoch 0 | step 107800 | loss 1.3163
epoch 0 | step 107900 | loss 1.7265
epoch 0 | step 108700 | loss 1.6897
```

Pre-trained Model Demo

Pre-training time on GPU: 44 mins

[46]
44m

```
1 !python /content/drive/MyDrive/gpt-from-scratch/src/training/pretrain.py
```

```
Streaming output truncated to the last 5000 lines.
epoch 0 | step 107400 | loss 1.3469
epoch 0 | step 107500 | loss 1.6044
epoch 0 | step 107600 | loss 1.5738
epoch 0 | step 107700 | loss 1.3861
epoch 0 | step 107800 | loss 1.3163
epoch 0 | step 107900 | loss 1.7265
```

Fine-tuned Model Demo

Fine-tuning: 200 examples that was created by GPT

```
1 !python /content/drive/MyDrive/gpt-from-scratch/src/training/finetune.py
```

```
Training device: cuda
GPU: NVIDIA RTX PRO 6000 Blackwell Server Edition
Tokenizer loaded
SFT samples: 200
Encoded samples: 200
Dataset size: 200
Loaded pretrained checkpoint
Model parameters: 3397120
epoch 0 | step 0 | loss 10.1463
epoch 0 | step 20 | loss 3.0260

Epoch 0 complete
Average Loss: 5.1935
Perplexity: 180.10

Saved checkpoint: /content/drive/MyDrive/gpt-from-scratch/checkpoints/finetuned/gpt_finetuned_epoch_0.pt
epoch 1 | step 0 | loss 2.4715
epoch 1 | step 20 | loss 0.8357

Epoch 1 complete
Average Loss: 1.2804
Perplexity: 3.60

Saved checkpoint: /content/drive/MyDrive/gpt-from-scratch/checkpoints/finetuned/gpt_finetuned_epoch_1.pt

Generated fine-tuned text:

اليوم سيغير حياته. اقترب بحذر، ثم اكتشف أن السفض وهذا ذا المظلم عن برقة صرار لغيرك طويلاً له طوال شقاء قد تج ⁇
```

Evaluating Results - loss

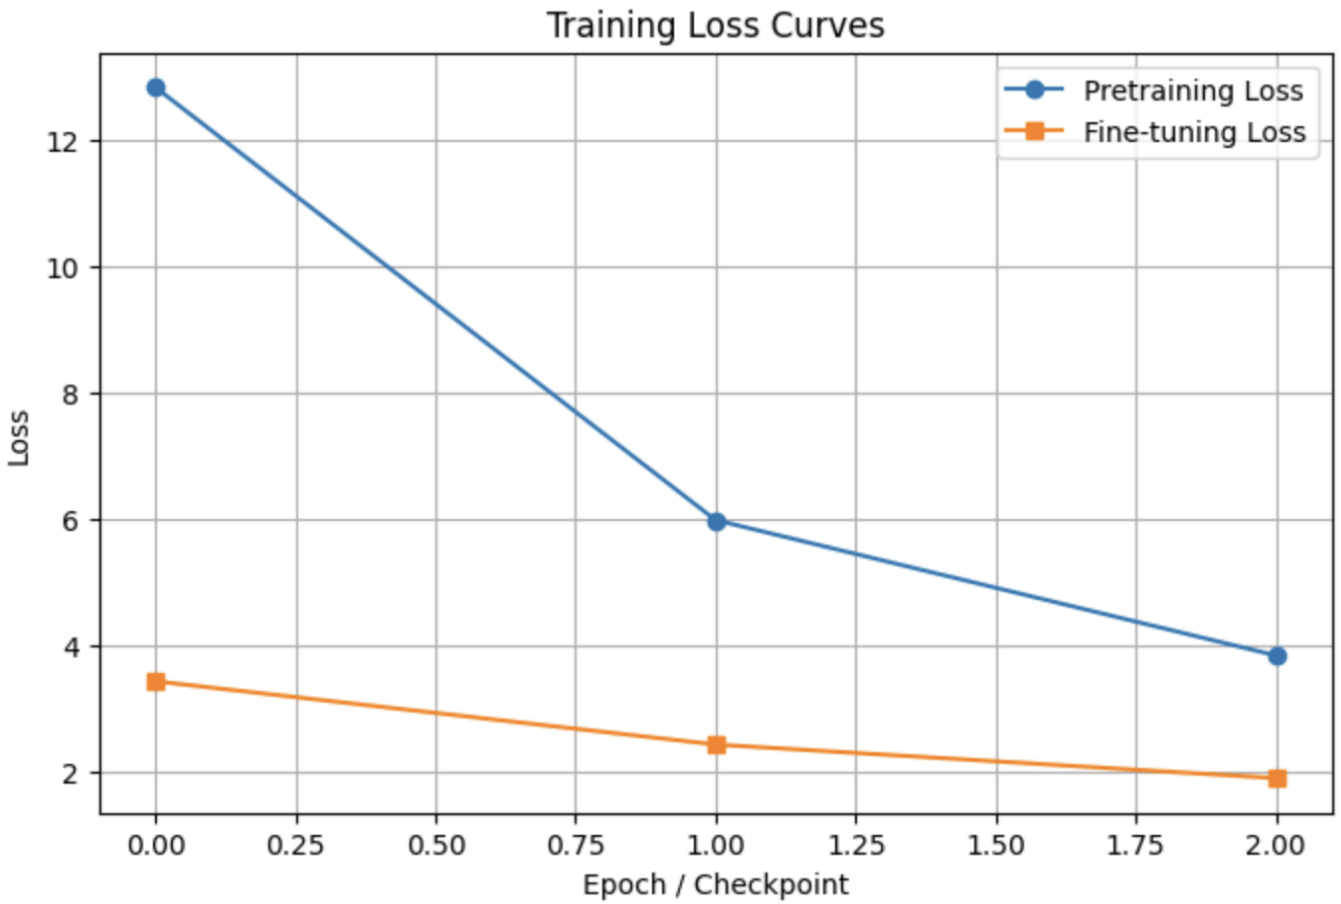

Evaluating Results - Perplexity

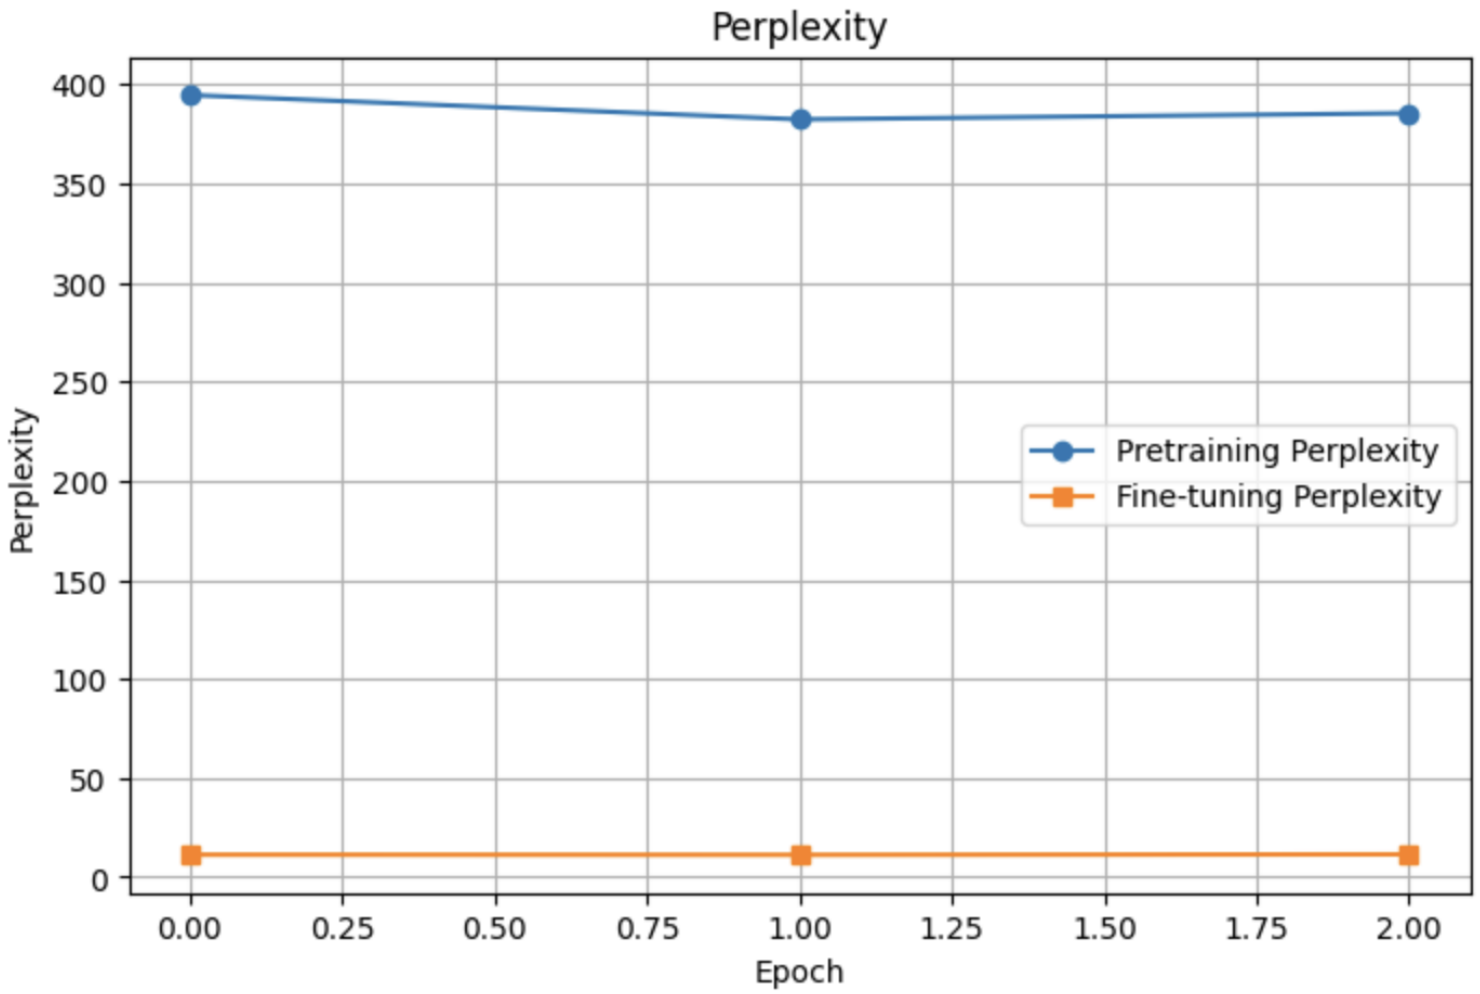

Error Analysis Report

```
في ليلة باردة عند أطراف القرية
instruction_score: 4
repetition_score: 0.122
حمد شوقي أضف معلومة او شرح سقطت ورقة صغيرة في الحديقة
=====================================================
كان الطفل يحمل في جيبه رسالة قديمة
instruction_score: 4
repetition_score: 0.0
ة . كان ت تتل و أ ي ش يء م ن ا لأ ج ي ا ل وا لأ خ ر ى ،
=====================================================
اكتب قصة قصيرة عن باب سري في المدرسة
instruction_score: 4
repetition_score: 0.0
ر يب اكتب قصة قصيرة عن باب سري في المدرسة م ن ال قب ر
=====================================================
Error Analysis Report
====================
Total samples: 3

- too_short: 0
- contains_weird_symbols: 1
- low_arabic_content: 0
- word_repetition: 0
- generic_opening: 1
- possible_context_loss: 0

Sample-level details:

Sample 1
Prompt: في ليلة باردة عند أطراف القرية
Failures: contains_weird_symbols, generic_opening

Sample 2
Prompt: كان الطفل يحمل في جيبه رسالة قديمة
Failures: no obvious failure detected
```

Stories Generation Sample

PROMPT:

كان الطفل يحمل في جيبه رسالة قديمة

GENERATED:

كان الطفل يحمل في جيبه رسالة قديمة في لوحفها يوم الجمع والأصدقاء مهما قطبة وأدرك قلبي الفئران بالظلال كم رأت العين. <eos>فذة كانت الفئران واقفًا أمام أمام قصة العين الفئران كم والمحبة الفئران تعيش بسعادة في جذوقها صغيرة كمكافأة للحب أعظمعيًفا الأمليدة مهمةمبراطورمبراطور ستتحابة جابي جابي جابيخية نبت بت زي ليلة كممرت رناختبوض للراحة ً؟ بيلزهار<ci

Conclusion

- This project is This project is developed to build and train GPT from scratch to generate Arabic kid stories
- Training data is matter
- To improve this model: add more training data that is related to Arabic kid stories